

Universität
Münster

QB Wissenschaftliches Arbeiten


Statistik VI – Logistische Regression

Dr. Michael Nolde


Themenübersicht

1. Motivation – Grenzen der linearen Regression
2. Wiederholung Odds & Odds Ratios
3. Das Modell der logistischen Regression
4. Interpretation
5. Modellselektion
6. Interaktionsterme
7. Modellannahmen

Lineare Regression mit binärem Outcome





Lineare Regression mit binärem Outcome



1 Motivation

Lineare Regression zur Klassifikation ist instabil



Lineare Regression mit binärem Outcome

Probleme:

- Das Outcome (bzw. die Residuen) ist nicht normalverteilt
- Das Verfahren wird instabil
- Wie soll man die vorhergesagten / gefitteten Werte interpretieren:
 - als binäres Outcome: dann müssten sie 0 oder 1 sein
 - als Wahrscheinlichkeiten: dann müssten sie zwischen 0 und 1 liegen

Die logistische Regression nutzt die Vorteile des linearen Regressionsmodells für diese Wertebereiche.
Allgemeiner Ansatz: Verallgemeinertes (generalisiertes) lineares Modell (GLM – **generalized** linear model)

2 Wiederholung Odds & Odds Ratios

Child's Class	Alive at 1 yr	Dead	Total	Prob. Alive	Odds of Alive	Odds Ratio
A	52	6	58			
B	78	17	95			
C	30	28	58			
Total	160	51	211			

2 Wiederholung Odds & Odds Ratios

Was sind Odds:

- Odds = $P/(1-P)$; Umgekehrt: $P = \text{Odds}/(1+\text{Odds})$
- Eine andere Skala zur Messung von Wahrscheinlichkeiten
- $0 \leq P \leq 1 \Rightarrow 0 \leq \text{Odds} \leq \infty \Rightarrow -\infty \leq \log \text{Odds} \leq \infty$

Was sind Odds Ratios:

- Ein Mittel zum Vergleich von Wahrscheinlichkeiten (Odds) zwischen 2 Gruppen
- $OR = \text{Odds}_1 / \text{Odds}_2$; $OR \geq 0$
 - $OR = 1 \Rightarrow$ beide Gruppen haben die gleichen Trefferwahrscheinlichkeiten
 - $OR > 1 \Rightarrow$ Gruppe 1 ist erfolgreicher
 - $OR < 1 \Rightarrow$ Gruppe 2 ist erfolgreicher

2 Wiederholung Odds & Odds Ratios

Probability = Odds/(1+Odds)	Odds = P/(1-P)	Log-Odds = ln(P/(1-P))
0.01	0.010	-4.60
0.05	0.052	-2.94
0.10	0.111	-2.20
0.25	0.333	-1.10
0.50	1	0
0.75	3	1.10
0.90	9	2.20
0.95	19	2.94
0.99	99	4.60

2 Wiederholung Odds & Odds Ratios

P_1	P_2	$P_1 - P_2$	$\text{Odds}_1 = \frac{P_1}{1 - P_1}$	$\text{Odds}_2 = \frac{P_2}{1 - P_2}$	$\text{OR} = \frac{\text{Odds}_1}{\text{Odds}_2}$	$\text{Log OR} = \ln(\text{Odds}_1 / \text{Odds}_2) = \ln \text{Odds}_1 - \ln \text{Odds}_2$
0.60	0.50	0.10	1.5	1.0	1.5	0.41
0.50	0.60	-0.10	1.0	1.5	0.67	-0.41
0.10	0.05	0.05	0.11	0.053	2.11	0.75
0.05	0.10	-0.05	0.053	0.11	0.47	-0.75

3 Das Modell der logistischen Regression

- Zielgröße: $\log\text{-odds} = \ln(p/(1-p))$
- Prädiktoren sind beliebig (numerisch, kategorial) wie in der linearen Regression
- Anwendungsgebiet:
 - Inferenz von Wahrscheinlichkeiten
 - Inferenz von binären Outcomes (Klassifikation)
 - Identifikation von Risikofaktoren
 - Kausale Inferenz (Adjustieren für Confounding)

3 Das Modell der logistischen Regression

$$\text{logit}(P) = \ln \frac{P}{1-P} = \underbrace{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{12} x_1 x_2 + \dots + \beta_p x_p}_{\text{linear predictor}}$$

- Linke Seite: logit der Trefferwahrscheinlichkeit ("log odds")
- Rechte Seite: linearer Prädiktor (wie bei der multiplen linearen Regression)
- Einflussgrößen können sein:
 - stetig: z.B. Alter, Biomarker, ...
 - dichotom: z.B. treatment v. control, Geschlecht
 - nominal mit >2 Gruppen: z.B. Gruppe A/B/C (→Dummykodierung)

3 Das Modell der logistischen Regression


$$\text{logit}(P) = \ln \frac{P(Y = 1 | x)}{1 - P(Y = 1 | x)} = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$$

$\Leftrightarrow$

$$P(Y = 1 | x) = \frac{\exp(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p)}{1 + \exp(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p)} = f(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p)$$

- logit heißt im Rahmen der GLM “link function”. Die Funktion verbindet den linearen Term (rechts) mit P
- Die „logistische“ Funktion ist die Umkehrfunktion f zur logit-Funktion

3 Das Modell der logistischen Regression



4 Interpretation

$$\text{logit}(P) = \ln \frac{P(Y = 1 | x)}{1 - P(Y = 1 | x)} = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$$

$\Leftrightarrow$

$$\frac{P}{1 - P} = \exp(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p) = e^{\beta_0} \cdot e^{\beta_1 x_1} \cdot \dots \cdot e^{\beta_p x_p}$$

- Auf der log odds Skala sind die Effekte linear (additiv)
- Auf der odds Skala sind die Effekte exponential multiplikativ

4 Interpretation

- Falls alle Prädiktoren $x_i = 0$ sind:

$$P(Y = 1|X = \beta_0) = \frac{1}{1+e^{-\beta_0}}$$

- Der Achsenabschnitt β_0 beschreibt das Grundrisiko (Baseline risk)
- Beachte:** In case-control Studien ist es nicht möglich, dieses Grundrisiko zu bestimmen. Dann gibt es keine sinnvolle Interpretation von β_0 .

4 Interpretation

- Was bewirkt die Veränderung eines stetigen Prädiktors um **eine Einheit** (alle anderen Prädiktoren werden konstant gehalten):

$$OR = \frac{\text{Odds}_{(x_j+1)}}{\text{Odds}_{x_j}} = \frac{e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_j (x_j+1) + \dots + \beta_k x_k}}{e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_j x_j + \dots + \beta_k x_k}} = \frac{e^{\beta_j (x_j+1)}}{e^{\beta_j x_j}} = e^{\beta_j}$$

- Dasselbe gilt für eine kategorische Variable beim Vergleich mit der Referenzgruppe
- Was passiert bei Interaktionstermen?

4 Interpretation

Regression coefficient	Odds ratio	Interpretation
$\beta_i < 0$	$e^{\beta_i} = OR_i < 1$	Protective effect
$\beta_i = 0$	$e^{\beta_i} = OR_i = 1$	No effect
$\beta_i > 0$	$e^{\beta_i} = OR_i > 1$	Increased risk

- Schätzung der Parameter in der **linearen Regression** mit der **Methode der kleinsten Quadrate** – das funktioniert hier nicht. Wieso?
- Stattdessen: **Maximum Likelihood Schätzung**
- Die Likelihood-Funktion **L** ist das Produkt der vorhergesagten Wahrscheinlichkeiten für die beobachteten Daten.

$$L = \prod_{\text{Treffer}} \hat{p}_i \cdot \prod_{\text{keine Treffer}} (1 - \hat{p}_i) \xrightarrow{\beta_0, \beta_1, \dots} \max$$
- Die Parameter β_i werden so bestimmt, dass L (in der Praxis $\log(L)$) maximal wird.
- 95% Konfidenzintervalle für die β_i werden mit Normalapproximation berechnet:
 - für das $\log(\text{OR})$ als $\beta_i \pm 1.96 \cdot \text{SE}(\beta_i)$
 - für das OR $\exp(\beta_i)$ nimmt man $\exp(\text{Intervallgrenzen})$ (nicht symmetrisch)

- **Lineare Regression:**

globaler Test: F-Statistik

Test für Regressionskoeffizient: Wald t-Test $t = \beta / SE(\beta)$

Bestimmtheitsmaß: r^2

- **Logistische Regression:**

Maß der Anpassungsgüte: **C-Statistik**

Test für Regressionskoeffizient: **Wald Test** $W = (\beta / SE(\beta))^2$ ist χ^2 -verteilt

Vergleich von Modellen: **Likelihood ratio test, AIC**

Bestimmtheitsmaß: **Pseudo- r^2**

5 Modellselektion

- Globaler Test (Goodness of Fit):

Wie bei einem diagnostischen Test (Vorlesung 2) beurteilt man die Güte des Modells anhand von Sensitivität und Spezifität in der ROC:

Sensitivität: Wsk. einen Treffer (1) richtig zu erkennen


Spezifität: Wsk. eine Niete (0) richtig zu erkennen

Ist für die logistische Regression abhängig vom Schwellenwert (cut-point)

ROC (Receiver Operating Characteristic) Kurve
variiert die Schwellenwerte

AUC (area under curve) misst Modellgüte
heißt **C-Statistik** (concordance statistic)

Modelltest: ist 0.5 im Konfidenzintervall der C-Statistik?



- Was bedeutet r^2 in der **linearen Regression**:
 - 1) erklärte Variabilität (im Sinne der Abweichungsquadrate)
 - 2) Verbesserung von angepasstem Modell verglichen mit dem Null-Modell
 - 3) Das Quadrat der Korrelation zwischen vorhergesagten und tatsächlichen Werten r^2 misst die Güte der Anpassung durch kleinste-Quadrate-Methode; Skala[0,1].
- Was bedeutet **Pseudo- r^2** in der **logistischen Regression**:

Es gibt viele verschiedene Pseudo- r^2 , die jeweils Aspekte davon nachbilden.
Die Skala [0,1] ist gleich angelegt. Beispiele:

 - McFadden (wie lin. Regression, aber mit $\log(L)$ anstelle der SAQ) (1,2)
 - Nagelkerke/Cragg & Uhler (komplizierter) (2)

- Vergleich von Modellen:

Die **Devianz** $D = -2 \log(L)$ wird zum Vergleich von Regressionsmodellen verwendet.

Für den Vergleich von Modell 1 und Modell 2 ist das **Likelihood Ratio LR**:

$$LR = D_1 - D_2 \sim \chi^2(1)$$

Wieso heißt das Likelihood Ratio?

- Abgeleitete Kenngröße **AIC** (Akaike-Information-Criterion):

Durch Hinzunahme von Variablen wird ein Modell automatisch exakter.

Deshalb wird ein Strafterm für die Anzahl der geschätzten Parameter aufgenommen.

$$AIC = -2 \log(L) + 2 \cdot \text{Anzahl der Parameter}(\beta_i)$$

6 Interaktionsterme

- Der Vergleich von Modellen ist interessant für **Prädiktionsmodelle**.
Wahl der Variablen anhand der Qualität der Vorhersage.
Das Interesse dabei gilt der Vorhersage des binären Outcomes.
- Was ist der Nutzen eines Modellvergleichs für **kausale Inferenz**:
Die Variablen werden durch ein kausales Modell (erstellt mit klinischem Vorwissen) ausgewählt.
Bestimmung der Interaktionsterme durch statistische Methoden.
Das Interesse dabei gilt dem Parameter β als Maß für kausalen Effekt.
Interaktionsterme können ein Zeichen sein für:
 - Effektmodifikation: die Intervention wirkt unterschiedlich in Gruppen.
 - Interaktion: zwei Interventionen beeinflussen einander gegenseitig.

7 Modellannahmen

- Keine Verteilungsannahmen an die Prädiktoren. Sie sollten allerdings nicht hochkorreliert sein.
- Die statistischen Methoden beruhen auf asymptotischen Verteilungen. Deshalb darf die Stichprobe nicht zu klein sein. Beide Ereignisse (0,1) müssen oft genug auftreten.
- „Rule of ten“, „one in ten rule“
Daumenregel: mind. 10 Ereignisse (0,1) pro unabhängiger Variable